

DEFESA DE BANCA • SSP/SP • 2022-2026

Análise espaço-temporal de crimes em São Paulo

Localização ajuda mais quando junto do horário?

Mapas • Clusterização • Modelo preditivo • Protótipo de URA do 190

Apresentadores: _____ • _____ • _____

A pergunta do trabalho

- Um mapa só com latitude e longitude acende quase sempre as mesmas áreas: Centro, Avenida Paulista, corredores comerciais — para quase todo tipo de crime. Isso mede onde há mais registro e circulação de pessoas — não o risco de quem mora ali. Pergunta: incluir o horário ajuda a separar melhor os tipos de ocorrência?

“

O mapa sozinho mede circulação e registro, não risco por morador.

É esse o ponto que o trabalho investiga.

Dados e filtros

2,08 mi

ocorrências após a limpeza


24

naturezas na base limpa

20

classes no modelo (após filtros)

- SSP/SP, município de São Paulo, 2022–2026 (corte 29/04/2026). Modelo usa só registros com coordenada válida e hora exata. Classes muito raras saem para permitir avaliação estratificada.
- **Forte desbalanceamento: Furto + Roubo $\approx$ 75% das ocorrências.**



Preparação das variáveis

1

Entrada do modelo. latitude, longitude e hora.

2

Hora é cíclica. vira seno e cosseno — 23h fica perto de 0h.


3

Tipo de crime é o ALVO. nunca entra como variável (seria vazamento).

4

Período em texto. só na exploração; o modelo usa hora exata.


Hora cíclica
0h · 23h



$\sin(2\pi h/24)$, $\cos(2\pi h/24)$


23h e 0h ficam próximas, como na vida real.

Mapa sem o horário



- A densidade se concentra no Centro e na região da Paulista. Tirando a Paulista, outras manchas continuam — corredores, terminais, vias movimentadas. **Lê concentração de registro e circulação, não risco por morador.**

Mapa com o horário



Assinatura horária por tipo de crime (fração por hora, normalizado por linha)

- Cada tipo de crime tem um horário típico:
 - Roubo de carga na parte da manhã;
 - Roubo de veículo à noite;
 - Roubos concentrados ao amanhecer e no final do dia;
 - Furtos durante o dia;
 - Apreensão de entorpecentes às 11 e 16 horas
- Observado nos dados — descreve o padrão, não afirma causa.

Visualização 3D

Longitude

eixo X

Latitude

eixo Y



Hora

eixo Z

cor = tipo de crime

- Mostra espaço (longitude/latitude) e tempo (hora) ao mesmo tempo, com o tipo de crime na cor. Serve para enxergar padrão e gerar hipótese — é apoio visual, não uma métrica. Arquivo interativo: reports/figures/crimes_3d_long_lat_tempo.html

Clusterização



- KMeans com latitude, longitude e hora (seno/cosseno); $k = 9$. **Silhouette $\approx 0,32$ — grupos pouco separados, muita sobreposição.** DBSCAN e HDBSCAN foram instáveis (de 1 cluster a dezenas, ou 56-80% de ruído).

O que os clusters sugerem

Os quatro maiores grupos ficam na MESMA região central — e se diferenciam pelo horário:

~3h

Madrugada

~9h

Manhã

~15h

Tarde

~20h

Noite

- O que a localização junta, o horário separa — conversa com a pergunta do trabalho. Furto e Roubo aparecem no topo de todos os grupos: o desbalanceamento domina o agrupamento. Tratamos isso como hipótese exploratória, não como prova de grupos naturais.

Modelo preditivo



- Saída: probabilidade de cada tipo de crime (20 classes). Comparados Dummy (base-rate), Regressão Logística, RandomForest e HistGradientBoosting. Split estratificado, semente fixa (≈930 mil treino / 310 mil teste). **Modelo escolhido pelo acerto da 1ª opção (top-1), não pelo top-3.**

Exemplo da URA do 190

Polícia Militar · 190

Selecione o tipo de ocorrência:

1. Roubo

2. Furto

3. Falar com atendente

menu curto: até 2 tipos + falar com atendente (sempre presente)

A ordem muda com local e horário:

Av. Paulista — 19h

1. Roubo 2. Furto

Zona Leste — 8h

1. Furto 2. Furto de veículo

- Ordena opções de menu. Não classifica a ocorrência nem decide o despacho.

Resultados do modelo

45,7% top-1

vs 36,2% da base-rate → +9,5 pp (o ganho real)


82,7% top-3

mas a base-rate já faz 81,2% — top-3 vem da distribuição

balanced accuracy 0,071 macro-F1 0,065

baixos: o modelo acerta as classes comuns e erra as raras.

Melhora o top-1; concentra previsões em Furto/Roubo; pouca leitura para crime raro.



Limitações e ética

Limitações

- Não distingue bem crime raro (macro-F1 baixo). Mapas refletem registro e circulação, não risco individual. Dados históricos podem carregar viés de notificação e de policiamento. Só três variáveis de entrada — local e hora levam até certo ponto.

Ética

- Protótipo acadêmico: ordena opções de menu, não decide. Sempre há a opção de falar com atendente humano. Não direciona policiamento nem despacho. Uso real exigiria validação temporal e auditoria de viés.

O que dá para defender

- O horário ajuda: os clusters centrais se separam por hora e o top-1 sobe +9,5 pp sobre a base-rate. O ganho é modesto e está no top-1 — o top-3 alto vem da distribuição das classes.
- Clustering serviu para levantar hipótese, não para provar grupos.
- A URA ordena opções de menu; não é decisão, e o atendente está sempre disponível.
- Próximos passos: variáveis de contexto, tratar desbalanceamento, validação temporal.